

Yükseköğretim Öğrencilerinin Akademik Başarı Düzeyinin Makine Öğrenmesi ile Tahmini

Dilber Cansu Toraman

Yönetim Bilişim Sistemleri Doktora Programı, MIS643 Veri Madenciliği
İstanbul Topkapı Üniversitesi — Öğrenci No: 25220903022
<https://github.com/jansuejj/veri-madenciligi-vize>

Özet—Bu çalışmada, yükseköğretim öğrencilerinin dönem sonu başarı düzeyini (Düşük / Orta / Yüksek) anket maddeleri ve ders bilgisinden tahmin eden, uçtan uca ve yeniden üretilebilir bir makine öğrenmesi akışı kurulmuştur. 145 gözlem ve 30 anket maddesinden oluşan veri seti üzerinde veri temizliği, hedef değişken dönüşümü ve özet özellik mühendisliği uygulanmış; altı farklı öğrenme ailesinden yedi sınıflandırma algoritması beş katlı tabakalı çapraz doğrulama ile karşılaştırılmıştır. Hiperparametre optimizasyonu (*GridSearchCV*) sonrasında en dengeli sonucu Random Forest modeli vermiş (çapraz doğrulama F1 = %68.6); model bağımsız test kümesinde %68.97 doğruluk, %67.07 ağırlıklı F1 ve 0.90 mikro-ortalama ROC AUC üretmiştir. Karmaşıklık matrisi ve ROC analizi, “Düşük” ve “Yüksek” sınıflarının komşu “Orta” sınıfa kıyasla daha kolay ayrıştığını; permütasyon önemleri ise ders kimliği ve anket maddelerinden türetilen özet değişkenlerin en ayırt edici sinyaller olduğunu göstermektedir. Veri setinin küçük ve sınıf dağılımının tam dengeli olmaması nedeniyle bulgular genelleme iddiası değil, şeffaf ve açıklanabilir bir temel olarak sunulmaktadır.

Anahtar Kelimeler—eğitim verisi madenciliği, öğrenci başarısı, çok sınıflı sınıflandırma, çapraz doğrulama, hiperparametre optimizasyonu, Random Forest.

I. GİRİŞ

Öğrenci başarısını sürecin içinde tahmin etmek, eğitim verisi madenciliğinin en görünür uygulama alanlarından biridir. Başarıyı yalnızca dönem sonunda ölçmek yerine, hangi öğrenme örüntülerinin düşük ya da yüksek performansla birlikte ortaya çıktığını erken görebilmek, hem öğretim tasarımı hem de öğrenci destek mekanizmalarını veriye dayalı biçimde planlamayı mümkün kılar.

Bu çalışmanın amacı en karmaşık modeli kurmak değil, sınırlı boyuttaki bir eğitim verisi üzerinde temiz, izlenebilir ve gerekçelendirilebilir bir işlem hattı oluşturmaktır. Bu nedenle veri ön işleme, dönüştürme, özellik mühendisliği, görselleştirme, model karşılaştırması ve hiperparametre optimizasyonu adımlarının her biri açıkça gösterilmiştir. Vize aşamasında üç modelle kurulan temel akış, bu final çalışmasında altı farklı öğrenme ailesine, hiperparametre optimizasyonuna, ROC analizine ve karmaşıklık matrisi tabanlı hata çözümlemesine genişletilmiştir.

Çalışmanın katkılarını şöyle özetlenebilir: (i) sekiz seviyeli ham notun yorumlanabilir üç başarı düzeyine dönüştürülmesi; (ii) öğrencinin genel yanıt örüntüsünü temsil eden üç özet özelliğin üretilmesi; (iii) yedi algoritmanın çoklu metrik ve çapraz doğrulama ile dürüst karşılaştırması; (iv) en iyi modelin sınıf bazında hata ve ayırt edicilik analizidir.

II. VERİ SETİ


Kullanılan veri seti, UCI Machine Learning Repository üzerinde yayımlanan *Higher Education Students Performance Evaluation* veri kümesidir [1]. Veri 145 öğrenci gözlemi ve 33 sütundan oluşur: öğrenci kimliği, 1–30 arası Likert tipi anket maddeleri, ders kimliği (COURSE ID) ve ham not (GRADE). Anket maddeleri öğrencilerin çalışma alışkanlıkları, hazırlık ve sosyodemografik durumlarına ilişkin kategorik yanıtları içerir.

Ham GRADE değişkeni 0–7 arası sekiz seviyelidir. Bu kadar

ince ayırım, 145 gözlemlili bir veri için seyrek sınıflara yol açtığından, eğitimsel olarak yorumlanabilir üç başarı düzeyine indirgenmiştir: $GRADE \in \{0, 1, 2\} \rightarrow \text{Düşük}$, $\{3, 4, 5\} \rightarrow \text{Orta}$, $\{6, 7\} \rightarrow \text{Yüksek}$. Dönüşüm sonrası sınıf dağılımı Düşük = 67, Orta = 48, Yüksek = 30 biçimindedir (Şekil 1). Sınıflar tam dengeli olmadığından değerlendirmede yalnızca doğruluk değil, sınıf duyarlı precision/recall/F1 metrikleri de raporlanmıştır. Veri setinin temel özellikleri Tablo 1’de özetlenmiştir.

TABLO 1. Veri Setinin Temel Özellikleri

Özellik	Değer
Gözlem sayısı	145
Toplam sütun sayısı	33
Anket maddesi sayısı	30
Eksik değer sayısı	0
Tekrarlı kayıt sayısı	0
Hedef değişken	GRADE $\rightarrow$ Düşük / Orta / Yüksek
Sınıf dağılımı	67 / 48 / 30



Şekil 1. Solda ham not (GRADE) dağılımı, sağda üç başarı düzeyine dönüştürülmüş dağılım.

III. YÖNTEM


A. Veri Temizleme

Veri setinde eksik hücre ve tekrarlı kayıt bulunmamaktadır; bu nedenle değer atama (imputation) veya satır silme gerekmemiştir. `drop_duplicates()` koruyucu amaçla çağırılmış, boyut değişmemiştir. Her gözlemi benzersiz etiketleyen STUDENT ID alanı, tahmin için açıklayıcı bilgi taşımadığı ve modele bırakılması gürültü/aşırı uyum riski yarattığı için çıkarılmıştır. Tüm anket maddeleri ortak Likert ölçeğinde olduğundan ek tip dönüşümü gerekmemiştir.

B. Özellik Mühendisliği ve Dönüştürme

Tek tek 30 maddeye ek olarak, öğrencinin genel yanıt örüntüsünü özetleyen üç türetilmiş değişken üretilmiştir: `soru_toplam` (maddelerin toplamı), `soru_ortalama` (ortalama yanıt seviyesi) ve `soru_std` (maddeler arası değişkenlik). Küçük veri setlerinde bu tür toplulaştırılmış sinyaller, özellikle ağaç tabanlı modellerde gürültüyü azaltarak ek ayırt edicilik sağlayabilmektedir. Anket maddeleri arası Pearson korelasyon ısı haritası (Şekil 2), maddeler arasında ilişkili kümelerin varlığını ve dolayısıyla özet değişkenlerin neden anlamlı olduğunu desteklemektedir.

Sayısal değişkenler `StandardScaler` ile standartlaştırılmış, kategorik COURSE ID değişkeni `OneHotEncoder` ile kodlanmıştır. Ardından `SelectKBest` (ANOVA F istatistiği) en bilgilendirici 15 özelliği seçer. Tüm bu adımlar her modelle birlikte tek bir Pipeline içinde çalıştırılmış; böylece ölçekleme ve özellik seçimi her çapraz doğrulama katında yalnızca eğitim verisine uydurularak veri sızıntısı önlenmiştir.




Şekil 2. Anket maddeleri (1–30) arası korelasyon ısı haritası. İlişkili kümeler özet değişkenlerin gerekçesini destekler.

C. Boyut İndirgeme Keşfi

Standartlaştırılmış 30 madde üzerinde PCA keşif amaçlı uygulanmıştır. İlk 10 bileşen toplam varyansın yaklaşık %61.01'ini açıklamakta, %80 varyans için 17 bileşen gerekmektedir (Şekil 3). Verinin içsel boyutluluğunun yüksek olması ve eğitim bağlamında hangi değişkenlerin etkili olduğunun okunur biçimde tartışılmak istenmesi nedeniyle PCA ana

modelleme hattına dahil edilmemiş; yalnızca yapıyı anlamaya yönelik bir yan analiz olarak değerlendirilmiştir.



Şekil 3. PCA kümülatif açıklanan varyans. İlk 10 bileşen varyansın ~%61'ini açıklar.

D. Modeller ve Değerlendirme Kurgusu

Rubriğin “farklı kategorilerden en az üç algoritma” beklentisini aşacak biçimde, altı farklı öğrenme ailesinden yedi model seçilmiştir: Logistic Regression (doğrusal), K-En Yakın Komşu (örnek-temelli), Destek Vektör Makinesi/RBF (çekirdek), Gaussian Naive Bayes (olasılıksal), Decision Tree (ağaç), Random Forest (bagging topluluğu) ve Gradient Boosting (boosting topluluğu).

Veri %80 eğitim ve %20 test olarak tabakalı biçimde ayrılmıştır. Test seti yalnızca en son adımda kullanılmış; model seçimi ve hiperparametre ayarı tamamen eğitim kümesi üzerindeki beş katlı tabakalı çapraz doğrulama ile yapılmıştır. Böylece doğrulama (validation) rolünü çapraz doğrulama üstlenmiş ve test üzerinde bilgi sızıntısı önlenmiştir. Her model için doğruluk yanında ağırlıklı precision, recall ve F1 hesaplanmıştır. Son olarak her model için `GridSearchCV` ile `f1_weighted` ölçütü üzerinden hiperparametre optimizasyonu yapılmış, en iyi model çok sınıflı (One-vs-Rest) ROC eğrileri ve karmaşıklık matrisi ile ayrıca çözümlenmiştir. Tüm uygulama `scikit-learn` [2] ile geliştirilmiştir.


IV. BULGULAR VE TARTIŞMA

A. Varsayılan Parametrelerle Karşılaştırma

Yedi modelin beş katlı çapraz doğrulama sonuçları Tablo 2 ve Şekil 4’de verilmiştir. Topluluk yöntemleri belirgin biçimde öne çıkmış; Gradient Boosting (F1 = %67.8) ve Random Forest (F1 = %64.9) ilk iki sırayı almıştır. KNN ve Naive Bayes en düşük F1 değerlerini üretmiştir; Naive Bayes’in görece yüksek doğruluğa karşın düşük F1’i, dengesiz sınıflar altında baskın sınıfa eğilim gösterdiğine işaret eder.

TABLO 2. Beş Katlı Çapraz Doğrulama ile Model Karşılaştırması (Varsayılan, %)

Model	Acc	Prec	Rec	F1
Gradient Boosting	68.1	69.9	68.1	67.8
Random Forest	65.7	66.9	65.7	64.9
Decision Tree	61.3	64.0	61.3	61.5
Logistic Regression	62.1	66.3	62.1	61.4
SVM (RBF)	60.5	64.6	60.5	58.6
Naive Bayes	63.8	51.3	63.8	53.0
KNN	54.3	51.5	54.3	51.1




Şekil 4. Modellere göre çapraz doğrulama F1 skoru (varsayılan hiperparametreler).

B. Hiperparametre Optimizasyonu

GridSearchCV ile her model küçük fakat anlamlı parametre ızgaralarında ayarlanmıştır. Optimizasyon sonrası sıralama Tablo 3'te ve karşılaştırma Şekil 5'de verilmiştir. En büyük kazanç Random Forest'ta görülmüş (F1 %64.9 → %68.6) ve bu model ayarlanmış çapraz doğrulamada Gradient Boosting'i (%67.8) geçerek en iyi konuma yerleşmiştir. Doğrusal ve örnek-temelli modeller ayarlamadan sınırlı fayda görmüştür; bu da problemin doğrusal olmayan ve topluluk yöntemlerine daha uygun yapısını desteklemektedir.

Tablo 3. Hiperparametre Optimizasyonu Sonrası Çapraz Doğrulama F1 (%)

Model	Vars.	Tuned	Kazanç
Random Forest	64.9	68.6	+3.7
Gradient Boosting	67.8	67.8	0.0
Logistic Regression	61.4	63.4	+2.0
Decision Tree	61.5	63.0	+1.5
SVM (RBF)	58.6	63.0	+4.4
Naive Bayes	53.0	53.0	0.0
KNN	51.1	51.2	+0.1



Şekil 5. Varsayılan ve ayarlanmış model çapraz doğrulama F1 karşılaştırması.

C. Test Kümesinde Nihai Değerlendirme

Ayarlanmış çapraz doğrulama F1'ine göre en iyi model olan Random Forest, tüm eğitim kümesine uydurulmuş ve ilk kez test kümesinde değerlendirilmiştir. Genel sonuçlar Tablo 4'te, sınıf bazlı sonuçlar Tablo 5'te verilmiştir. Model %68.97 doğruluk, %68.43 ağırlıklı precision, %68.97 ağırlıklı recall ve %67.07 ağırlıklı F1 üretmiştir.

Tablo 4. En İyi Modelin (Random Forest) Test Sonuçları

Metrik	Değer (%)
Accuracy	68.97
Weighted Precision	68.43
Weighted Recall	68.97
Weighted F1	67.07
Mikro-ortalama ROC AUC	89.8


Tablo 5. Sınıf Bazlı Test Metrikleri ve ROC AUC

Sınıf	Prec	Rec	F1	AUC
Düşük	0.75	0.92	0.83	0.91
Orta	0.67	0.40	0.50	0.78
Yüksek	0.57	0.67	0.62	0.96

Karmaşıklık matrisi (Şekil 6) ve ROC eğrileri (Şekil 7) tutarlı bir hikâye anlatır: model “Düşük” (F1 = 0.83, AUC = 0.91) ve “Yüksek” (AUC = 0.96) sınıflarını başarıyla ayırırken, en çok “Orta” sınıfında zorlanmaktadır (F1 = 0.50, AUC = 0.78). Bu beklenen bir sonuçtur: orta düzey, başarı sürekliliğinde komşu iki düzeye doğal olarak örtüşür ve karmaşıklık matrisinde hatalar ağırlıklı Orta ile Düşük/Yüksek arasında oluşur. Hatalı sınıflandırmaların bitişik düzeyler arasında yoğunlaşması, modelin sıralı yapıyı yakaladığını da gösterir.

		Confusion Matrix - Random Forest		
True label	Dusuk	12	1	0
	Orta	3	4	3
	Yüksek	1	1	4
		Dusuk	Orta	Yüksek
		Predicted label		


Şekil 6. En iyi modelin (Random Forest) test kümesi karmaşıklık matrisi.




Şekil 7. En iyi model için çok sınıflı (One-vs-Rest) ROC eğrileri ve mikro-ortalama.

D. Özellik Önemleri

Test kümesi üzerinde hesaplanan permütasyon önemleri (Şekil 8), COURSE ID değişkeninin açık ara en ayırt edici sinyal olduğunu; bunu 29. anket maddesi ve türetilmiş soru_toplam değişkeninin izlediğini göstermektedir. Ders kimliğinin baskınlığı, ders bağlamının (ders zorluğu, değerlendirme biçimi) başarı düzeyiyle güçlü ilişkili olduğuna işaret eder; nitekim Şekil 9 bazı derslerin belirgin biçimde belirli başarı düzeyleriyle ilişkilendiğini göstermektedir. Türetilmiş özet değişkenin ilk sıralarda yer alması, tek tek maddeler kadar öğrencinin genel yanıt örüntüsünün de bilgi taşıdığını doğrular.



Şekil 8. En önemli 12 özellik (permütasyon önemi, F1 düşüşü).



Şekil 9. Ders kimliğine göre başarı düzeyi dağılımı.

E. Sınırlılıklar

Veri seti küçüktür (145 gözlem) ve sınıf dağılımı tam dengeli değildir; özellikle Yüksek sınıfında test gözlemi azdır (6 örnek), bu da sınıf bazlı metrikleri oynak kılar. Ayrıca sütun adlarının içerik açıklaması olmadan sayısal gelmesi, maddelerin pedagojik anlamı üzerine güçlü iddialar kurmayı zorlaştırır. COURSE ID'nin baskın önemi, ders bağlamının güçlü bir gösterge olduğunu düşündürmekle birlikte, gözlemlerin derslere dengesiz dağılımı nedeniyle temkinli yorumlanmalıdır.

V. SONUÇ

Bu çalışmada, yükseköğretim öğrencilerine ait anket ve ders verileri kullanılarak üç sınıflı bir başarı tahmini problemi, şeffaf ve yeniden üretilebilir bir işlem hattıyla ele alınmıştır. Altı farklı öğrenme ailesinden yedi model arasında, hiperparametre optimizasyonu sonrası en dengeli sonucu Random Forest vermiş; test kümesinde %68.97 doğruluk ve 0.90 mikro-ortalama ROC AUC elde edilmiştir. Bulgular, ders bağlamının ve anket maddelerinden türetilen özet değişkenlerin başarı düzeyiyle anlamlı ilişkili olduğunu ortaya koymaktadır.

Asıl önemli nokta yalnızca en yüksek skoru bulmak değildir; küçük ölçekli eğitim verilerinde süreç şeffaflığı, model gerekçesi ve sınırlılıkların doğru ifade edilmesi en az sonuç kadar değerlidir. Eyleme dönük içgörü olarak, ders bağlamının erken bir risk göstergesi olarak izlenmesi ve düşük genel yanıt örüntüsü (soru_toplam) sergileyen öğrencilere erken destek sağlanması önerilebilir.

Gelecek çalışmalar için öneriler: (i) madde içeriklerinin açıklamalarıyla birlikte pedagojik yorumun derinleştirilmesi; (ii) sınıf dengesizliğine karşı SMOTE benzeri örnekleme veya sınıf ağırlıklandırma denemesi; (iii) veri sayısı arttığında XGBoost/LightGBM gibi güçlü topluluk yöntemleri ve istiflenmiş (stacking) modellerle karşılaştırma; (iv) ders bazında ayrı modelleme ile bağlam etkisinin ayrıştırılması. Kod dosyalarının GitHub üzerinden sürümlemesi, çalışmanın tekrar üretilebilirliğini güçlendirmektedir.

KAYNAKÇA

- [1] UCI Machine Learning Repository, "Higher Education Students Performance Evaluation Dataset," erişim: Nisan 2026.
- [2] F. Pedregosa ve diğ., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, c. 12, ss. 2825–2830, 2011.
- [3] L. Breiman, "Random Forests," *Machine Learning*, c. 45, sy. 1, ss. 5–32, 2001.
- [4] T. Hastie, R. Tibshirani ve J. Friedman, *The Elements of Statistical Learning*, 2. bs. New York: Springer, 2009.
- [5] J. H. Friedman, "Greedy Function Approximation: A Gradient Boosting Machine," *Annals of Statistics*, c. 29, sy. 5, ss. 1189–1232, 2001.