

# Yükseköğretim Öğrencilerinin Akademik Başarı Düzeyinin Makine Öğrenmesi ile Tahmini

Dilber Cansu Toraman

Yönetim Bilişim Sistemleri Doktora Programı, MIS643 Veri Madenciliği  
İstanbul Topkapı Üniversitesi — Öğrenci No: 25220903022  
<https://github.com/jansuejj/veri-madenciligi-final>

**Abstract**—This study builds an end-to-end and reproducible machine-learning pipeline that predicts the end-of-term academic achievement level (Low / Medium / High) of higher-education students from questionnaire items and course information. On a dataset of 145 observations and 30 questionnaire items, data cleaning, target transformation and summary feature engineering were applied; *eight advanced* classification algorithms—ensemble methods (Gradient Boosting, HistGradient Boosting, AdaBoost, Extra Trees and a Stacking meta-model), a kernel method (SVM-RBF), an instance-based method (KNN) and a deep-learning model (a multi-layer perceptron neural network)—were compared using five-fold stratified cross-validation. These models deliberately differ from the baseline linear/tree models used in the midterm. After hyperparameter optimization (*GridSearchCV*), AdaBoost gave the most balanced result (cross-validation F1 = %68.7) and, on the held-out test set, achieved %75.86 accuracy, %74.54 weighted F1 and 0.87 micro-averaged ROC AUC—a clear improvement over the midterm baseline. Confusion-matrix and ROC analyses show that the “Low” and “High” classes are separated more easily than the neighbouring “Medium” class, while permutation importance indicates that the course identifier and the summary features derived from the questionnaire items are the most discriminative signals. An additional unsupervised K-Means clustering analysis examines the natural grouping of students from a different, label-free perspective. Because the dataset is small and the class distribution is not perfectly balanced, the findings are presented not as a generalization claim but as a transparent and explainable baseline.

**Index Terms**—educational data mining, student performance, multi-class classification, ensemble learning, neural networks, clustering.

**Özet**—Bu çalışmada, yükseköğretim öğrencilerinin dönem sonu başarı düzeyini (Düşük / Orta / Yüksek) anket maddeleri ve ders bilgisinden tahmin eden, uçtan uca ve yeniden üretilebilir bir makine öğrenmesi akışı kurulmuştur. 145 gözlem ve 30 anket maddesinden oluşan veri seti üzerinde veri temizliği, hedef değişken dönüşümü ve özet özellik mühendisliği uygulanmış; *vize aşamasından farklı, daha gelişmiş* sekiz algoritma — topluluk yöntemleri (Gradient Boosting, HistGradient Boosting, AdaBoost, Extra Trees ve bir Stacking meta-modeli), bir çekirdek yöntemi (SVM-RBF), bir örnek-temelli yöntem (KNN) ve bir derin öğrenme modeli (çok katmanlı yapay sinir ağı) — beş katlı tabakalı çapraz doğrulama ile karşılaştırılmıştır. Hiperparametre optimizasyonu (*GridSearchCV*) sonrasında en dengeli sonucu AdaBoost modeli vermiş (çapraz doğrulama F1 = %68.7); model bağımsız test kümesinde %75.86 doğruluk, %74.54 ağırlıklı F1 ve 0.87 mikro-ortalama ROC AUC üreterek vize temel çizgisini belirgin biçimde geçmiştir. Karmaşıklık matrisi ve ROC analizi, “Düşük” ve “Yüksek” sınıflarının komşu “Orta” sınıfa kıyasla daha kolay ayrıştığını; permütasyon önemleri ise ders kimliği ve anket maddelerinden türetilen özet değişkenlerin en ayırt edici sinyaller olduğunu göstermektedir. Ek olarak gözetimsiz bir K-Means kümeleme analizi, öğrencilerin doğal gruplanmasını etiketsiz bir bakış açısıyla incelemektedir. Veri setinin küçük ve sınıf dağılımının tam dengeli olmaması nedeniyle bulgular genelleme iddiası değil, şeffaf ve açıklanabilir bir temel olarak sunulmaktadır.

**Anahtar Kelimeler**—eğitim verisi madenciliği, öğrenci başarısı, çok sınıflı sınıflandırma, topluluk öğrenmesi, yapay sinir ağları, kümeleme.

## I. GİRİŞ

Öğrenci başarısını sürecin içinde tahmin etmek, eğitim verisi madenciliğinin en görünür uygulama alanlarından biridir [7]. Başarıyı yalnızca dönem sonunda ölçmek yerine, hangi öğrenme örüntülerinin düşük ya da yüksek performansla birlikte ortaya çıktığını erken görebilmek, hem öğrenim tasarımı hem de öğrenci destek mekanizmalarını veriye dayalı biçimde planlamayı mümkün kılar.

Bu çalışmanın amacı en karmaşık modeli kurmak değil, sınırlı boyuttaki bir eğitim verisi üzerinde temiz, izlenebilir ve gerekçelendirilebilir bir işlem hattı oluşturmaktır. Bu nedenle veri ön işleme, dönüştürme, özellik mühendisliği, görselleştirme, model karşılaştırması ve hiperparametre optimizasyonu adımlarının her biri açıkça gösterilmiştir. Vize aşamasında temel modellerle (Lojistik Regresyon, Karar Ağacı, Random Forest) kurulan akış, bu final çalışmasında bilinçli

olarak *daha gelişmiş ve farklı* yöntemlere genişletilmiştir: gelişmiş topluluk (ensemble) algoritmaları, bir çekirdek yöntemi, bir derin öğrenme (yapay sinir ağı) modeli ve bir stacking meta-modeli. Ayrıca sınıflandırmaya, gözetimsiz bir kümeleme analizi de eklenerek probleme farklı bir açıdan bakılmıştır.

Çalışmanın katkıları şöyle özetlenebilir: (i) sekiz seviyeli ham notun yorumlanabilir üç başarı düzeyine dönüştürülmesi; (ii) öğrencinin genel yanıt örüntüsünü temsil eden üç özet özelliğin üretilmesi; (iii) vizeden farklı, gelişmiş sekiz algoritmanın (topluluk + çekirdek + derin öğrenme + stacking) çoklu metrik ve çapraz doğrulama ile dürüst karşılaştırması; (iv) en iyi modelin sınıf bazında hata ve ayırt edicilik analizi; (v) gözetimsiz K-Means kümeleme ile tamamlayıcı bir analiz.


## II. VERİ SETİ

Kullanılan veri seti, UCI Machine Learning Repository üzerinde yayımlanan *Higher Education Students Performance Evaluation* veri kümesidir [1]. Veri 145 öğrenci gözlemi ve 33 sütundan oluşur: öğrenci kimliği, 1–30 arası Likert tipi anket maddeleri, ders kimliği (COURSE ID) ve ham not (GRADE). Anket maddeleri öğrencilerin çalışma alışkanlıkları, hazırlık ve sosyodemografik durumlarına ilişkin kategorik yanıtları içerir.

Ham GRADE değişkeni 0–7 arası sekiz seviyeli. Bu kadar ince ayırım, 145 gözlemlili bir veri için seyrek sınıflara yol açtığından, eğitimsel olarak yorumlanabilir üç başarı düzeyine indirgenmiştir:  $GRADE \in \{0, 1, 2\} \rightarrow \text{Düşük}$ ,  $\{3, 4, 5\} \rightarrow \text{Orta}$ ,  $\{6, 7\} \rightarrow \text{Yüksek}$ . Dönüşüm sonrası sınıf dağılımı Düşük = 67, Orta = 48, Yüksek = 30 biçimindedir (Şekil 1). Sınıflar tam dengeli olmadığından değerlendirmede yalnızca doğruluk değil, sınıf duyarlı precision/recall/F1 metrikleri de raporlanmıştır. Veri setinin temel özellikleri Tablo 1’de özetlenmiştir.

TABLO 1. Veri Setinin Temel Özellikleri

| Özellik               | Değer                                     |
|-----------------------|-------------------------------------------|
| Gözlem sayısı         | 145                                       |
| Toplam sütun sayısı   | 33                                        |
| Anket maddesi sayısı  | 30                                        |
| Eksik değer sayısı    | 0                                         |
| Tekrarlı kayıt sayısı | 0                                         |
| Hedef değişken        | GRADE $\rightarrow$ Düşük / Orta / Yüksek |
| Sınıf dağılımı        | 67 / 48 / 30                              |



Şekil 1. Solda ham not (GRADE) dağılımı, sağda üç başarı düzeyine dönüştürülmüş dağılım.

## III. YÖNTEM

### A. Veri Temizleme


Veri setinde eksik hücre ve tekrarlı kayıt bulunmamaktadır; bu nedenle değer atama (imputation) veya satır silme gerekmemiştir. `drop_duplicates()` koruyucu amaçla çağrılmış, boyut değişmemiştir. Her gözlemi benzersiz etiketleyen STUDENT ID alanı, tahmin için açıklayıcı bilgi taşımadığı ve modele bırakılması gürültü/aşırı uyum riski yarattığı için çıkarılmıştır. Tüm anket maddeleri ortak Likert ölçeğinde olduğundan ek tip dönüşümü gerekmemiştir.

### B. Özellik Mühendisliği ve Dönüştürme

Tek tek 30 maddeye ek olarak, öğrencinin genel yanıt örüntüsünü özetleyen üç türetilmiş değişken üretilmiştir: `soru_toplam` (maddelerin toplamı), `soru_ortalama` (ortalama yanıt seviyesi) ve `soru_std` (maddeler arası değişkenlik). Küçük veri setlerinde bu tür toplulaştırılmış sinyaller,

özellikle ağaç tabanlı modellerde gürültüyü azaltarak ek ayırt edicilik sağlayabilmektedir. Anket maddeleri arası Pearson korelasyon ısı haritası (Şekil 2), maddeler arasında ilişkili kümelerin varlığını ve dolayısıyla özet değişkenlerin neden anlamlı olduğunu desteklemektedir.


Sayısal değişkenler `StandardScaler` ile standartlaştırılmış, kategorik COURSE ID değişkeni `OneHotEncoder` ile kodlanmıştır. Ardından `SelectKBest` (ANOVA F istatistiği) en bilgilendirici 15 özelliği seçer. Tüm bu adımlar her modelle birlikte tek bir Pipeline içinde çalıştırılmış; böylece ölçekleme ve özellik seçimi her çapraz doğrulama katında yalnızca eğitim verisine uydurularak veri sızıntısı önlenmiştir.



Şekil 2. Anket maddeleri (1–30) arası korelasyon ısı haritası. İlişkili kümeler özet değişkenlerin gerekçesini destekler.


### C. Boyut İndirgeme Keşfi

Standartlaştırılmış 30 madde üzerinde PCA keşif amaçlı uygulanmıştır. İlk 10 bileşen toplam varyansın yaklaşık %61.01’ini açıklamakta, %80 varyans için 17 bileşen gerekmektedir (Şekil 3). Verinin içsel boyutluluğunun yüksek olması ve eğitim bağlamında hangi değişkenlerin etkili olduğunun okunur biçimde tartışılmak istenmesi nedeniyle PCA ana modelleme hattına dahil edilmemiş; yalnızca yapıyı anlamaya yönelik bir yan analiz olarak değerlendirilmiştir.



Şekil 3. PCA kümülatif açıklanan varyans. İlk 10 bileşen varyansın ~%61’ini açıklar.

İlk iki PCA bileşeni üzerinde gözlemlerin saçılımı, başarı düzeylerinin özellik uzayında büyük ölçüde iç içe geçtiğini göstermektedir (Şekil 4). “Düşük” ve “Yüksek” uçlar kenarlara doğru hafifçe ayrışsa da “Orta” düzey iki bulutun arasına yayılmakta; bu örüntü, sonraki bölümde gözlenen “Orta” sınıfa ait düşük ayırt ediciliği ve birkaç aykırı gözlemin varlığını görsel olarak doğrular.



Şekil 4. İlk iki PCA bileşeni uzayında başarı düzeyine göre gözlem saçılımı. Sınıf bulutları belirgin biçimde iç içedir.

#### D. Modeller ve Değerlendirme Kurgusu

Bu final çalışmasında, vize aşamasında kullanılan temel modeller (Lojistik Regresyon, Karar Ağacı, Random Forest) bilinçli olarak *kullanılmamış*; bunların yerine aynı veri seti üzerinde daha gelişmiş ve farklı sekiz algoritma uygulanmıştır: **Gradient Boosting** [5], **HistGradient Boosting** (modern, XGBoost benzeri boosting), **AdaBoost** [6] ve **Extra Trees** [3] (gelişmiş topluluk yöntemleri); **Destek Vektör Makinesi** [4] (RBF çekirdeği); **K-En Yakın Komşu** (örnek-temelli); **çok katmanlı yapay sinir ağı** (MLP) (derin öğrenme); ve birkaç modeli birleştiren bir **Stacking** meta-topluluğu. Böylece topluluk (bagging/boosting/stacking), çekirdek ve derin öğrenme aileleri birlikte temsil edilmiştir.

Veri %80 eğitim ve %20 test olarak tabakalı biçimde ayrılmıştır. Test seti yalnızca en son adımda kullanılmış; model seçimi ve hiperparametre ayarı tamamen eğitim kümesi üzerindeki beş katlı tabakalı çapraz doğrulama ile yapılmıştır. Böylece doğrulama (validation) rolünü çapraz doğrulama üstlenmiş ve test üzerinde bilgi sızıntısı önlenmiştir. Her model için doğruluk yanında ağırlıklı precision, recall ve F1 hesaplanmıştır. Son olarak her model için GridSearchCV ile  $f1\_weighted$  ölçütü üzerinden hiperparametre optimizasyonu yapılmış, en iyi model çok sınıflı (One-vs-Rest) ROC eğrileri ve karmaşıklık matrisi ile ayrıca çözümlenmiştir. Tüm uygulama scikit-learn [2] ile geliştirilmiştir.

### IV. BULGULAR VE TARTIŞMA


#### A. Varsayılan Parametrelerle Karşılaştırma

Sekiz modelin beş katlı çapraz doğrulama sonuçları Tablo 2 ve Şekil 5’de verilmiştir. Boosting tabanlı topluluk yöntemleri belirgin biçimde öne çıkmış; Gradient Boosting ( $F1 = \%67.8$ ), Stacking ( $\%66.0$ ) ve AdaBoost ( $\%65.6$ ) ilk üç sırayı almıştır. Derin öğrenme modeli (MLP) ve SVM orta düzeyde kalmış; KNN en düşük F1 değerini üretmiştir. Bu tablo, problemin

doğrusal olmayan ve topluluk yöntemlerine uygun yapısını destekler.

TABLO 2. Beş Katlı Çapraz Doğrulama ile Model Karşılaştırması (Varsayılan, %)

| Model                 | Acc  | Prec | Rec  | F1          |
|-----------------------|------|------|------|-------------|
| Gradient Boosting     | 68.1 | 69.9 | 68.1 | <b>67.8</b> |
| Stacking              | 67.3 | 70.3 | 67.3 | 66.0        |
| AdaBoost              | 66.4 | 69.8 | 66.4 | 65.6        |
| Extra Trees           | 65.6 | 67.5 | 65.6 | 65.0        |
| HistGradient Boosting | 62.1 | 64.4 | 62.1 | 61.2        |
| MLP (Sinir Ağı)       | 61.3 | 61.6 | 61.3 | 60.6        |
| SVM (RBF)             | 60.5 | 64.6 | 60.5 | 58.6        |
| KNN                   | 54.3 | 51.5 | 54.3 | 51.1        |




Şekil 5. Modellere göre çapraz doğrulama F1 skoru (varsayılan hiperparametreler).

#### B. Hiperparametre Optimizasyonu

GridSearchCV ile her model küçük fakat anlamlı parametre ızgaralarında ayarlanmıştır. Optimizasyon sonrası sıralama Tablo 3’te ve karşılaştırma Şekil 6’de verilmiştir. En büyük kazanç SVM ( $\%58.6 \rightarrow \%63.0$ ) ve AdaBoost’ta ( $\%65.6 \rightarrow \%68.7$ ) görülmüş; ayarlama sonrası **AdaBoost** çapraz doğrulamada Extra Trees ve Gradient Boosting’i (her ikisi  $\%67.8$ ) geçerek en iyi konuma yerleşmiştir. Bu sonuç, boosting tabanlı topluluk yöntemlerinin bu veri setinde en dengeli genelleme davranışını sunduğunu göstermektedir.

TABLO 3. Hiperparametre Optimizasyonu Sonrası Çapraz Doğrulama F1 (%)

| Model                 | Vars. | Tuned       | Kazanç |
|-----------------------|-------|-------------|--------|
| AdaBoost              | 65.6  | <b>68.7</b> | +3.1   |
| Extra Trees           | 65.0  | 67.8        | +2.8   |
| Gradient Boosting     | 67.8  | 67.8        | 0.0    |
| Stacking              | 66.0  | 66.0        | 0.0    |
| SVM (RBF)             | 58.6  | 63.0        | +4.4   |
| HistGradient Boosting | 61.2  | 61.2        | 0.0    |
| MLP (Sinir Ağı)       | 60.6  | 60.6        | 0.0    |
| KNN                   | 51.1  | 51.2        | +0.1   |



Şekil 6. Varsayılan ve ayarlanmış model çapraz doğrulama F1 karşılaştırması.

### C. Test Kümesinde Nihai Değerlendirme

Ayarlanmış çapraz doğrulama F1'ine göre en iyi model olan AdaBoost, tüm eğitim kümesine uydurulmuş ve ilk kez test kümesinde değerlendirilmiştir. Genel sonuçlar Tablo 4'te, sınıf bazlı sonuçlar Tablo 5'te verilmiştir. Model %75.86 doğruluk, %75.37 ağırlıklı precision, %75.86 ağırlıklı recall ve %74.54 ağırlıklı F1 üretmiştir. Bu değerler, vize aşamasındaki temel modelin (%68.97 doğruluk, %66.99 F1) belirgin biçimde üzerindedir; gelişmiş topluluk yöntemine geçişin somut bir kazanç sağladığını göstermektedir.


TABLO 4. En İyi Modelin (AdaBoost) Test Sonuçları

| Metrik                 | Değer (%) |
|------------------------|-----------|
| Accuracy               | 75.86     |
| Weighted Precision     | 75.37     |
| Weighted Recall        | 75.86     |
| Weighted F1            | 74.54     |
| Mikro-ortalama ROC AUC | 87.0      |


TABLO 5. Sınıf Bazlı Test Metrikleri ve ROC AUC

| Sınıf  | Prec | Rec  | F1   | AUC  |
|--------|------|------|------|------|
| Düşük  | 0.79 | 0.85 | 0.82 | 0.89 |
| Orta   | 0.71 | 0.50 | 0.59 | 0.72 |
| Yüksek | 0.75 | 1.00 | 0.86 | 0.96 |

Karmaşıklık matrisi (Şekil 7) ve ROC eğrileri (Şekil 8) tutarlı bir hikâye anlatır: model “Yüksek” (F1 = 0.86, AUC = 0.96) ve “Düşük” (F1 = 0.82, AUC = 0.89) sınıflarını başarıyla ayırırken, en çok “Orta” sınıfında zorlanmaktadır (F1 = 0.59, AUC = 0.72). Bu beklenen bir sonuçtur: orta düzey, başarı sürekliliğinde komşu iki düzeyle doğal olarak örtüşür ve karmaşıklık matrisinde hatalar ağırlıklı Orta ile Düşük/Yüksek arasında oluşur. Hatalı sınıflandırmaların bitişik düzeyler arasında yoğunlaşması, modelin sıralı yapıyı yakaladığını da gösterir.




Şekil 7. En iyi modelin (AdaBoost) test kümesi karmaşıklık matrisi.




Şekil 8. En iyi model için çok sınıflı (One-vs-Rest) ROC eğrileri ve mikro-ortalama.

### D. Özellik Önemleri

Test kümesi üzerinde hesaplanan permütasyon önemleri (Şekil 9), COURSE ID değişkeninin açık ara en ayırt edici sinyal olduğunu (önem  $\approx 0.29$ ); bunu 29. ve 2. anket maddelerinin izlediğini göstermektedir. Ders kimliğinin baskınlığı, ders bağlamının (ders zorluğu, değerlendirme biçimi) başarı düzeyiyle güçlü ilişkili olduğuna işaret eder; nitekim Şekil 10 bazı derslerin belirgin biçimde belirli başarı düzeyleriyle ilişkilendiğini göstermektedir. Belirli anket maddelerinin öne çıkması ise öğrencinin bazı çalışma/hazırlık alışkanlıklarının başarı düzeyiyle bağlantılı olduğunu düşündürmektedir.




Şekil 9. En önemli 12 özellik (permütasyon önemi, F1 düşüşü).



Şekil 10. Ders kimliğine göre başarı düzeyi dağılımı.

#### E. COURSE ID'siz Sağlıklik Kontrolü


COURSE ID'nin baskın önemi, modelin gerçekte öğrencinin yanıt örüntüsünü mü yoksa büyük ölçüde ait olduğu dersi mi öğrendiği sorusunu doğurur. Bu olası karıştırıcı (*confounding*) etkiyi sınamak için tüm modeller COURSE ID tamamen çıkarılarak (yalnızca anket maddeleri ve özet değişkenlerle) yeniden eğitilmiş ve çapraz doğrulama F1 skorları COURSE ID'li sürümle karşılaştırılmıştır (Şekil 11). Sonuçlar çarpıcıdır: ders kimliği çıkarıldığında tüm modellerde performans belirgin biçimde düşmüş, en iyi modelin (AdaBoost) test doğruluğu %75.86'dan %48.28'e, ağırlıklı F1 skoru ise 0.745'ten 0.460'a gerilemiştir. Bu düzey, üç sınıflı problemde çoğunluk sınıfını (*Düşük*,  $\approx 46\%$ ) tahmin etmeye yakındır. Dolayısıyla tahmin gücünün büyük kısmı ders bağlamından gelmekte; anket maddeleri tek başına başarı düzeyini ayırt etmekte sınırlı kalmaktadır. Bu, modelin bir kusuru değil verinin bir özelliğidir ve eğitsel açıdan ders bağlamının (zorluk, değerlendirme biçimi) başlı başına güçlü bir gösterge olduğunu vurgular.




Şekil 11. Her model için COURSE ID'li ve COURSE ID'siz çapraz doğrulama F1 karşılaştırması. Ders kimliği çıkarıldığında tüm modellerde belirgin düşüş gözlenir.

#### F. Gözetimsiz Kümeleme Analizi

Sınıflandırmayı tamamlamak ve probleme etiketsiz bir açıdan bakmak için ölçeklenmiş özellik uzayında **K-Means** kümelemesi uygulanmıştır. Farklı küme sayıları için silhouette skorları hesaplanmış (Şekil 12); skorların düşük ve birbirine yakın olması (en yüksek  $\approx 0.08$ ), verinin keskin biçimde ayırık doğal kümeler içermediğini gösterir. Üç başarı düzeyiyle kıyaslamak için  $k = 3$  seçilmiş; kümelerin gerçek başarı düzeyleriyle uyumu Adjusted Rand Index (ARI) ile ölçülmüştür ve  $ARI \approx 0.02$  bulunmuştur. Bu düşük değer, kümelerin başarı düzeyleriyle yalnızca zayıf örtüştüğünü; yani başarı düzeyinin gözetimsiz olarak kolayca ayrışmadığını ortaya koyar. Bu sonuç, sınıflandırmada gözlenen sınıf örtüşmesiyle (özellikle Orta sınıf) tutarlıdır. Kümelerin PCA ile iki boyuta indirgenmiş dağılımı Şekil 13'de görülmektedir.



Şekil 12. Farklı küme sayıları için silhouette skoru.



Şekil 13. KMeans kümelerinin PCA 2B uzayındaki dağılımı.

### G. Sınırlılıklar

Veri seti küçüktür (145 gözlem) ve sınıf dağılımı tam dengeli değildir; özellikle Yüksek sınıfında test gözlemi azdır (6 örnek), bu da sınıf bazlı metrikleri oynak kılar. Ayrıca sütun adlarının içerik açıklaması olmadan sayısal gelmesi, maddelerin pedagojik anlamı üzerine güçlü iddialar kurmayı zorlaştırır. COURSE ID'nin baskın önemi, ders bağlamının güçlü bir gösterge olduğunu düşündürmekle birlikte, gözlemlerin derslere dengesiz dağılması nedeniyle temkinli yorumlanmalıdır.

### V. SONUÇ

Bu çalışmada, yükseköğretim öğrencilerine ait anket ve ders verileri kullanılarak üç sınıflı bir başarı tahmini problemi, şeffaf ve yeniden üretilebilir bir işlem hattıyla ele alınmıştır. Vize aşamasındaki temel modellerden farklı olarak, gelişmiş topluluk yöntemleri, bir çekirdek yöntemi, bir derin öğrenme (yapay sinir ağı) modeli ve bir stacking meta-modeli karşılaştırılmıştır. Hiperparametre optimizasyonu sonrası en dengeli sonucu **AdaBoost** vermiş; test kümesinde %75.86 doğruluk ve 0.87 mikro-ortalama ROC AUC elde edilmiş, böylece vize temel çizgisi belirgin biçimde açılmıştır. Ek gözetimsiz kümeleme analizi, başarı düzeylerinin etiketsiz bir uzayda yalnızca zayıf ayrıştığını göstermiştir. Bulgular, ders bağlamının ve anket maddelerinin başarı düzeyiyle anlamlı ilişkili olduğunu ortaya koymaktadır.

Asıl önemli nokta yalnızca en yüksek skoru bulmak değildir; küçük ölçekli eğitim verilerinde süreç şeffaflığı, model gerekçesi ve sınırlılıkların doğru ifade edilmesi en az sonuç kadar değerlidir. Eyleme dönük içgörü olarak, ders bağlamının erken bir risk göstergesi olarak izlenmesi ve düşük genel yanıt örüntüsü (*soru\_toplam*) sergileyen öğrencilere erken destek sağlanması önerilebilir. Nitekim COURSE ID'siz sağlamlık kontrolü, tahmin gücünün büyük kısmının ders bağlamından geldiğini ortaya koymuştur; bu da destek müdahalelerinin ders düzeyinde tasarlanmasının, tek tek anket maddelerine odaklanmaktan daha etkili olabileceğini düşündürür.

Gelecek çalışmalar için öneriler: (i) madde içeriklerinin açıklamalarıyla birlikte pedagojik yorumun derinleştirilmesi; (ii) sınıf dengesizliğine karşı SMOTE benzeri örnekleme veya sınıf ağırlıklandırma denenmesi; (iii) veri sayısı arttığında XGBoost/LightGBM gibi kütüphanelerle ve daha derin sinir ağı mimarileriyle karşılaştırma; (iv) ders bazında ayrı modelleme ile bağlam etkisinin ayrıştırılması. Kod dosyaları ve veri seti GitHub üzerinden sürümlenerek çalışmanın tekrar üretilebilirliği güçlendirilmiştir.

### KAYNAKÇA

- [1] UCI Machine Learning Repository, “Higher Education Students Performance Evaluation Dataset,” erişim: Nisan 2026.
- [2] F. Pedregosa ve diğ., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, c. 12, ss. 2825–2830, 2011.
- [3] L. Breiman, “Random Forests,” *Machine Learning*, c. 45, sy. 1, ss. 5–32, 2001.
- [4] T. Hastie, R. Tibshirani ve J. Friedman, *The Elements of Statistical Learning*, 2. bs. New York: Springer, 2009.
- [5] J. H. Friedman, “Greedy Function Approximation: A Gradient Boosting Machine,” *Annals of Statistics*, c. 29, sy. 5, ss. 1189–1232, 2001.
- [6] Y. Freund ve R. E. Schapire, “A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting,” *Journal of Computer and System Sciences*, c. 55, sy. 1, ss. 119–139, 1997.
- [7] C. Romero ve S. Ventura, “Educational Data Mining: A Review of the State of the Art,” *IEEE Trans. Systems, Man, and Cybernetics*, c. 40, sy. 6, ss. 601–618, 2010.